

Un protocole de prévision reproductible pour les banques centrales africaines

Validation walk-forward, tests de Diebold–Mariano et Model Confidence Set,
combinaison optimale de Bates–Granger.

Application à l'IHPC de la Côte d'Ivoire (1997-2026)

Boni MONNEY Jean

Direction Générale de l'Économie (DGE)

Ministère de l'Économie, des Finances et du Budget — République de Côte d'Ivoire

Mai 2026

Document de travail

JEL : C22 · C45 · C53 · E31 · E37

Résumé

Cet article propose un protocole de prévision de l'inflation reproductible adapté aux contraintes des banques centrales africaines, et l'applique à l'indice harmonisé des prix à la consommation (IHPC) de la Côte d'Ivoire sur 350 observations mensuelles allant de janvier 1997 à février 2026. Le protocole comporte quatre composantes méthodologiques. La première est une validation walk-forward (rolling origin) avec 18 origines de prévision et quatre horizons d'évaluation ($h \in \{1, 3, 6, 12\}$), qui remplace le découpage train-test fixe encore largement utilisé dans la littérature appliquée africaine. La deuxième est l'évaluation systématique des prévisions sur six métriques (MAE, RMSE, MASE, MAPE, SMAPE, U de Theil), permettant de vérifier que les conclusions ne dépendent pas du choix de la fonction de perte. La troisième est l'inférence statistique formelle, à travers le test de Diebold–Mariano avec correction Harvey–Leybourne–Newbold pour petits échantillons et la procédure du Model Confidence Set de Hansen et al. (2011), implémentée avec bootstrap par blocs circulaires et 5 000 répliques. La quatrième est la combinaison optimale de Bates–Granger (1969) avec pondérations corrigées de la covariance des erreurs. Cinq modèles sont comparés : ARIMA avec sélection automatique par AIC, lissage exponentiel triple de Holt–Winters, marche aléatoire avec dérive, réseau récurrent à longue mémoire (LSTM) et architecture neuronale hiérarchique d'interpolation (NHITS). L'application livre trois résultats. D'abord, NHITS atteint un MASE de 0,94 à $h = 1$, devenant le seul modèle à battre le benchmark de marche aléatoire in-sample. Ensuite, Holt–Winters est l'unique élément du Model Confidence Set à $h = 12$ et $\alpha = 25 \%$, ce qui en fait le choix robuste pour la prévision annuelle. Enfin, la combinaison Bates–Granger de NHITS et Holt–Winters produit un gain mesurable de 4,84 % à l'horizon trimestriel et conduit à une prévision d'inflation à douze mois de +1,52 %, à l'intérieur de la bande cible 1–3 % de la BCEAO. L'ensemble du code est diffusé sous licence MIT pour faciliter l'adoption du protocole par d'autres économies africaines.

Mots-clés : prévision de l'inflation ; ARIMA ; Holt-Winters ; LSTM ; NHITS ; validation walk-forward ; test de Diebold–Mariano ; Model Confidence Set ; combinaison de Bates–Granger ; banques centrales africaines ; Côte d'Ivoire ; UEMOA.

Classification JEL : C22 (Modèles de séries temporelles), C45 (Réseaux de neurones), C53 (Méthodes de prévision), E31 (Inflation), E37 (Prévision et simulation).

1. Introduction

La prévision de l'inflation occupe une place centrale dans la conduite de la politique monétaire et dans la programmation budgétaire. Pour les banques centrales africaines, et en particulier pour celles qui opèrent dans des unions monétaires comme l'UEMOA ou la CEMAC, des prévisions fiables sont indispensables au respect des critères de convergence et à la crédibilité des annonces de politique. La Banque Centrale des États de l'Afrique de l'Ouest (BCEAO) cible une bande d'inflation de 1 à 3 % par an pour l'Union, et les déviations persistantes par rapport à cette bande — comme celles observées lors de la flambée inflationniste de 2022 liée au conflit russo-ukrainien et aux séquelles des perturbations d'approvisionnement post-pandémie — se traduisent rapidement en coûts de crédibilité et compliquent la programmation pluriannuelle.

La pratique de prévision dans les administrations économiques africaines reste pourtant marquée par des protocoles d'évaluation hétérogènes, qui rendent les résultats difficiles à comparer entre études et entre pays. Trois limitations méthodologiques sont récurrentes. Premièrement, l'évaluation des prévisions repose souvent sur un découpage train-test unique et fixe, ce qui rend les conclusions sensibles à la date de partition et offre peu de garantie de généralisation. Deuxièmement, les comparaisons entre modèles s'appuient sur des estimations ponctuelles de métriques d'erreur, sans test statistique formel permettant de distinguer une différence réelle d'une variation d'échantillonnage. Troisièmement, la combinaison de prévisions, dont la littérature économétrique a depuis longtemps démontré l'intérêt (Bates et Granger, 1969 ; Clemen, 1989 ; Timmermann, 2006), n'est presque jamais validée empiriquement contre les modèles individuels.

Cet article propose un protocole de prévision reproductible qui adresse ces trois limitations, et l'applique à l'indice harmonisé des prix à la consommation (IHPC) de la Côte d'Ivoire, la plus grande économie de l'UEMOA. L'IHPC est compilé mensuellement par l'Institut National de la Statistique (INS-CI) et notre série couvre près de trente ans d'observations, de janvier 1997 à février 2026. Cette longueur d'échantillon permet d'évaluer la performance des modèles à travers plusieurs régimes structurels : la stabilisation post-dévaluation de la fin des années 1990, la crise politico-militaire de 2002, le rebasement méthodologique de l'indice en 2008, la normalisation post-électorale de 2011, le choc Covid-19 de 2020 et l'accélération inflationniste de 2022.




Figure 1. Évolution mensuelle de l'IHPC ivoirien (janvier 1997 – février 2026, n = 350). Source : INS-CI. La couleur de fond identifie les périodes d'entraînement (bleu) et de test (orange) utilisées dans cette étude.

1.1 Contributions

L'article apporte quatre contributions à la littérature appliquée sur la prévision de l'inflation en Afrique.

Première contribution : nous adoptons un protocole de validation walk-forward (rolling origin) avec 18 origines de prévision et quatre horizons d'évaluation ($h \in \{1, 3, 6, 12\}$). Ce protocole, bien établi dans la littérature internationale (Hyndman et Athanasopoulos, 2021), reste rare dans les études appliquées africaines, où le découpage train-test fixe domine encore. Le walk-forward fournit 347 prévisions par cellule modèle–horizon et permet une évaluation robuste, peu sensible à la date particulière de partition.

Deuxième contribution : nous mobilisons un test pairwise (Diebold–Mariano avec correction Harvey–Leybourne–Newbold pour petits échantillons) et une procédure de sélection multiple (Model Confidence Set de Hansen et al., 2011, implémentée avec bootstrap par blocs circulaires et $B = 5\,000$ répliques), ce qui permet de distinguer formellement les différences de précision réelles des variations d'échantillonnage.

Troisième contribution : nous comparons cinq modèles couvrant l'éventail des approches utilisées en banque centrale, depuis le benchmark de marche aléatoire avec dérive d'Atkeson et Ohanian (2001) jusqu'à l'architecture neuronale moderne NHITS introduite par Oreshkin et al. (2020). Le LSTM (Hochreiter et Schmidhuber, 1997) et Holt-Winters (Winters, 1960) complètent la comparaison, aux côtés d'un ARIMA avec sélection automatique d'ordre par AIC. Cette diversité de modèles permet de tester l'hypothèse, parfois avancée, selon laquelle les méthodes d'apprentissage profond surpasseraient mécaniquement les approches classiques sur les séries d'inflation.

Quatrième contribution : nous validons empiriquement la combinaison Bates–Granger (1969) avec pondérations optimales corrigées de la covariance des erreurs, en distinguant clairement les horizons où la combinaison apporte un gain réel de

ceux où elle est dominée par le meilleur modèle individuel. Cette validation est importante car la littérature sur le « paradoxe de la combinaison de prévisions » (Hsiao et Wan, 2014) met en garde contre les combinaisons mal calibrées.

1.2 Plan

La section 2 passe en revue les littératures pertinentes sur les modèles classiques et neuronaux, sur les tests de précision et sur la combinaison de prévisions. La section 3 décrit les données et expose le protocole méthodologique. La section 4 présente les résultats empiriques. La section 5 discute des implications opérationnelles pour les banques centrales africaines et précise les limites du travail. La section 6 conclut sur les perspectives de recherche et les conditions de réplication du protocole dans d'autres économies de la région.

2. Revue de littérature

2.1 Modèles classiques de séries temporelles

Le cadre ARIMA de Box et Jenkins (1970) reste la référence standard dans la pratique de prévision des banques centrales. Pour les économies africaines et en développement en particulier, Pufnik et Kunovac (2006) ainsi qu'Alnaa et Ahiakpor (2011) documentent une bonne performance d'ARIMA aux horizons courts et une dégradation rapide au-delà de six mois, un schéma que nous retrouverons dans nos données. Le lissage exponentiel triple dans la tradition de Winters (1960) fournit un complément parcimonieux qui décompose la série en composantes de niveau, tendance et saisonnalité, et il est particulièrement adapté aux séries d'IPC mensuelles présentant de fortes régularités saisonnières (Hyndman et Athanasopoulos, 2021). La marche aléatoire avec dérive, popularisée dans le contexte de l'inflation par Atkeson et Ohanian (2001), est le troisième modèle classique que nous utilisons. Leur résultat original pour les États-Unis — selon lequel les prévisions naïves simples égalent ou dépassent souvent celles fondées sur la courbe de Phillips — a été reproduit dans de nombreux contextes et c'est la raison pour laquelle nous incluons systématiquement ce benchmark.

2.2 Approches neuronales

L'application des réseaux de neurones à la prévision macroéconomique remonte au moins à Chen et al. (2001), McAdam et McNelis (2005) et Nakamura (2006). L'architecture LSTM de Hochreiter et Schmidhuber (1997) est devenue la référence de la famille des réseaux récurrents grâce à son mécanisme de mémoire à portes, qui atténue le problème du gradient évanescent. La compétition M4 (Makridakis et al., 2018) a marqué un tournant : l'entrée gagnante de Smyl (2020) combinait lissage exponentiel et réseau récurrent, ce qui suggère que ni les approches purement statistiques ni les approches purement neuronales ne sont universellement optimales. Oreshkin et al. (2020) ont ensuite introduit N-BEATS, une architecture fondée sur l'interpolation hiérarchique et les connexions résiduelles rétrogrades qui abandonne la récurrence ; son successeur NHITS étend cette approche avec une décomposition multi-résolution explicite et a été le modèle purement neuronal le plus performant sur les extensions M4.

Pour les économies africaines spécifiquement, la littérature appliquée combinant approches classiques et neuronales reste encore embryonnaire. Suhartono (2005) avait montré dans le contexte indonésien que les méthodes neuronales pouvaient compléter utilement les modèles ARIMA. Plus récemment, plusieurs études ont commencé à explorer l'apprentissage profond pour la prévision d'indicateurs économiques africains, mais le manque d'un protocole d'évaluation standardisé rend les comparaisons inter-études difficiles. Notre travail s'inscrit dans cette littérature en proposant un cadre méthodologique unifié qui peut être réutilisé par d'autres équipes de recherche en Afrique de l'Ouest et du Centre.

2.3 Tests de précision et sélection de modèles

Le test de Diebold–Mariano (1995) est l'outil standard pour la comparaison de prévisions par paires. La correction pour petits échantillons proposée par Harvey, Leybourne et Newbold (1997) est essentielle lorsque l'échantillon de test est court ou que l'horizon de prévision est long, car la distribution asymptotique standard devient peu fiable dans ces contextes. L'estimateur de variance HAC de Newey et West (1987) est normalement utilisé dans les implémentations DM. Pour des comparaisons sur plusieurs modèles, la procédure du Model Confidence Set de Hansen, Lunde et Nason (2011) identifie le sous-ensemble de modèles dont la précision est statistiquement indistinguishable de celle du meilleur performant à un niveau de confiance donné. Le MCS procède par élimination séquentielle, et son implémentation requiert une procédure de rééchantillonnage — typiquement le bootstrap par blocs circulaires de Politis et Romano (1992), qui préserve la structure d'autocorrélation des différentiels de perte.

Le test de capacité prédictive conditionnelle de Giacomini et White (2006) étend le cadre DM en permettant le conditionnement sur des instruments, et il est particulièrement utile lorsque l'on souhaite évaluer si la performance de prévision varie systématiquement avec des conditions économiques observables. Nous n'utilisons pas ce test dans la présente étude car nous nous concentrons sur des comparaisons inconditionnelles, mais il représente une extension naturelle pour des travaux futurs.

2.4 Combinaison de prévisions

L'optimalité des combinaisons linéaires de prévisions a été établie par Bates et Granger (1969). Sous l'hypothèse d'absence de biais, la combinaison linéaire de deux prévisions avec des pondérations déterminées par leurs erreurs quadratiques moyennes et leur covariance d'erreurs est garantie d'être au moins aussi précise que la meilleure des deux, avec amélioration stricte sauf si l'une domine strictement l'autre. Clemen (1989) et Timmermann (2006) passent en revue la littérature et soulignent deux régularités empiriques importantes : la pondération égale simple est souvent étonnamment performante en pratique (le « paradoxe de la combinaison de prévisions »), et les pondérations optimales estimées sur de petits échantillons sont bruyantes et peuvent produire des combinaisons sous-performantes par rapport aux modèles individuels. Hsiao et Wan (2014) fournissent des conditions sous lesquelles la combinaison optimale est empiriquement bénéfique. Faust et Wright (2013) passent en revue la littérature spécifique à l'inflation. Notre exercice empirique confirme que le bénéfice de la combinaison dépend de l'horizon et n'est pas automatique.

3. Données et méthodologie

3.1 Données

Nos données sont constituées de 350 observations mensuelles de l'IHPC pour la Côte d'Ivoire de janvier 1997 à février 2026, compilées par l'INS-CI sur une base 2014 = 100. Le Tableau 1 résume les statistiques descriptives. La série montre une forte tendance haussière sur l'échantillon (moyenne 78,12, plage 41,93 à 105,05) et une volatilité modérée (écart-type 18,73). Les tests de racine unitaire standard (ADF, Phillips-Perron, KPSS — résultats omis pour la concision) confirment la non-stationnarité en niveaux et la stationnarité en différences premières, ce qui motive l'usage de modèles intégrés. Plusieurs ruptures structurelles sont visibles sur la Figure 1 : la crise de 2002, le rebasement méthodologique de l'indice en 2008 (où le niveau passe de 56,44 à 72,85 entre décembre 2007 et janvier 2008 à la suite d'une redéfinition du panier de consommation et de l'année de référence), et les chocs plus récents Covid-19 et Ukraine. Ces ruptures auront leur importance pour l'interprétation des résultats neuronaux en particulier.

Tableau 1. Statistiques descriptives — IHPC Côte d'Ivoire.

Statistique	Valeur
Nombre d'observations	350
Période	Janvier 1997 – Février 2026
Fréquence	Mensuelle
Source	INS-CI (ANStat)
Année de base	2023 = 100
Moyenne	78,12
Écart-type	18,73
Minimum	41,93 (janvier 1997)
Maximum	105,05 (août 2024)
Dernière observation	104,50 (février 2026)

3.2 Modèles

3.2.1 ARIMA

Nous ajustons ARIMA(p, d, q) avec sélection automatique de l'ordre via AIC. L'observation intéressante est que, sur chaque échantillon d'entraînement walk-forward, la spécification sélectionnée par AIC se réduit systématiquement à ARIMA(0, 1, 0) avec tendance linéaire — ce qui est algébriquement équivalent à une marche aléatoire avec dérive. Ce résultat est cohérent avec la littérature sur la prévision de

l'inflation (Atkeson et Ohanian, 2001 ; Faust et Wright, 2013) et conduit à une équivalence formelle avec notre benchmark Naive ci-dessous. Nous traitons cela comme une vérification de cohérence interne plutôt que comme un résultat séparé.

3.2.2 Holt-Winters

Holt-Winters additif avec période saisonnière $s = 12$ et tendance amortie, estimé par maximum de vraisemblance selon Hyndman et al. (2008). La spécification additive est préférée à la forme multiplicative parce que le coefficient de variation de la série est relativement faible et nous ne trouvons pas de preuves d'effets saisonniers proportionnels.

3.2.3 Naive (marche aléatoire avec dérive)

Le benchmark Naive est la marche aléatoire avec dérive, $\hat{y}(t+h) = y(t) + h \cdot \delta$, avec δ estimé comme la variation moyenne période sur période sur l'échantillon d'entraînement. Il est inclus principalement comme point de référence et comme moyen de valider, ex post, l'équivalence $\text{ARIMA}(0,1,0)+\text{dérive} \equiv \text{Naive}$ lorsque la première spécification est sélectionnée par AIC. Suivant l'argument d'Atkeson et Ohanian (2001), ce benchmark est notoirement difficile à battre sur des séries d'inflation, et toute méthode qui ne le surpasse pas devrait être traitée avec scepticisme.

3.2.4 LSTM

L'architecture LSTM (Hochreiter et Schmidhuber, 1997) est implémentée dans TensorFlow/Keras. Sept hyperparamètres sont optimisés avec le Tree-structured Parzen Estimator (Bergstra et al., 2011) tel qu'implémenté dans Optuna (Akiba et al., 2019) : fenêtre de lookback (12–24), unités dans la première couche (32/64/128), nombre de couches (1 ou 2), unités dans la seconde couche (16/32/64), taux de dropout (0,0–0,3), taux d'apprentissage ($1e-4$ à $1e-2$, log-uniforme) et taille de batch (16 ou 32). Nous utilisons deux régimes de calcul pour gérer l'arbitrage entre exhaustivité et temps d'exécution. Le régime « fast » utilise 10 essais Optuna effectifs et 20 époques maximum et est appliqué dans le walk-forward à 18 origines pour maintenir le temps total d'exécution sous 9 heures CPU. Le régime « standard » utilise 20 essais et 200 époques et est appliqué dans l'exercice out-of-sample et comme vérification de robustesse.

3.2.5 NHITS

NHITS (Oreshkin et al., 2020) est implémenté via la bibliothèque neuralforecast d'Olivares et al. (2022), à travers le wrapper AutoNHITS avec Ray Tune comme backend d'optimisation. Pour garder la comparaison équitable, nous utilisons les deux mêmes régimes de calcul que pour LSTM : « fast » avec 6 essais et 100 étapes d'entraînement maximum, et « standard » avec 30 essais et 1 000 étapes. Cette symétrie de calcul entre les deux architectures neuronales est essentielle pour une comparaison méthodologiquement fondée.

3.3 Validation walk-forward

La précision des prévisions est évaluée à travers un protocole walk-forward illustré dans la Figure 2. La fenêtre d'entraînement initiale comprend 85 % de l'échantillon ($n_{\text{train}} = 296$ observations, janvier 1997 – août 2021). À chaque origine de prévision t , tous les modèles sont ajustés sur les données jusqu'à t et sont chargés de produire des prévisions à h pas en avant pour $h \in \{1, 3, 6, 12\}$. L'origine est ensuite avancée d'un mois, et le processus se répète. Nous utilisons 18 origines distinctes allant de septembre 2021 à février 2023, ce qui génère 347 prévisions par combinaison modèle–horizon sur la fenêtre de test.




Figure 2. Schéma du protocole de validation walk-forward avec 18 origines de prévision (rolling origin) et horizons jusqu'à douze mois. La fenêtre d'entraînement croît avec chaque origine ; les prévisions aux horizons un, trois, six et douze sont évaluées contre les valeurs réalisées.

Nous préférons le protocole walk-forward au découpage train/test unique fixe pour deux raisons. Il fournit une estimation plus robuste de la précision out-of-sample attendue, moins sensible à la date particulière choisie pour la partition. Et il reflète le scénario de déploiement opérationnel, dans lequel les prévisions sont révisées au fur et à mesure que de nouvelles observations arrivent. Cette approche est cohérente avec les recommandations de Hyndman et Athanasopoulos (2021, Section 5.10) sur la validation croisée pour séries temporelles. Pour les banques centrales africaines qui produisent des prévisions mensuelles ou trimestrielles dans un contexte de données limitées, le walk-forward représente un outil méthodologique particulièrement adapté.

3.4 Métriques d'évaluation

Nous calculons six métriques, chacune capturant un aspect distinct de la qualité de prévision. Avec $y(t)$ la valeur réalisée et $\hat{y}(t)$ la prévision sur un échantillon de test de taille n : MAE est l'erreur absolue moyenne,

RMSE est la racine de l'erreur quadratique moyenne, MASE est l'erreur absolue échelonnée de Hyndman et Koehler (2006), MAPE est le pourcentage d'erreur absolue moyenne, SMAPE est sa variante symétrique de Makridakis (1993), et U de Theil est le coefficient d'inégalité de Theil (1966), borné entre 0 et 1. MASE est notre métrique principale car elle est invariante à l'échelle (ce qui la rend comparable entre études) et parce qu'une valeur inférieure à l'unité est un signal fort que le modèle bat la marche aléatoire in-sample. Le U de Theil a été spécifiquement ajouté pour faciliter la comparaison avec la littérature macroéconométrique où c'est un standard de longue date.

3.5 Tests statistiques

3.5.1 Diebold–Mariano avec correction HLN

Pour chaque paire de modèles (A, B) et chaque horizon h , nous testons l'hypothèse nulle d'égalité de précision prédictive $E[L(e_A) - L(e_B)] = 0$ en utilisant Diebold et Mariano (1995) avec la correction pour petits échantillons de Harvey et al. (1997). La statistique corrigée HLN est $DM_HLN = DM \times \sqrt{[(n + 1 - 2h + h(h - 1)/n) / n]}$, et la valeur p est calculée contre la distribution Student- t à $n - 1$ degrés de liberté.

3.5.2 Model Confidence Set

La procédure MCS de Hansen et al. (2011) identifie le sous-ensemble de modèles dont la précision est statistiquement équivalente à celle du meilleur performant, au niveau de confiance α . Nous rapportons l'appartenance au MCS à $\alpha = 0,10$ et $\alpha = 0,25$. La procédure procède par élimination séquentielle des modèles dominés ; les valeurs critiques bootstrap sont calculées via bootstrap par blocs circulaires (Politis et Romano, 1992) avec $B = 5\,000$ répliques et longueur de bloc $L = 3$.

3.6 Combinaison de prévisions

Suivant Bates et Granger (1969), la combinaison linéaire optimale de deux prévisions non biaisées $\hat{y}_A$ et $\hat{y}_B$ est $\hat{y}_{\text{combo}} = \alpha \cdot \hat{y}_A + (1 - \alpha) \cdot \hat{y}_B$, avec la pondération optimale $\alpha^* = (\sigma^2_B - \sigma_{AB}) / (\sigma^2_A + \sigma^2_B - 2\sigma_{AB})$, où σ^2_A et σ^2_B sont les erreurs quadratiques moyennes des deux prévisions et σ_{AB} leur covariance d'erreurs. Nous validons empiriquement trois variantes de pondération sur les sorties walk-forward : une heuristique linéaire $\alpha_{\text{linear}}(h) = \max(0, 1 - h/6)$, la pondération naïve de Bates–Granger ignorant la covariance $\alpha_{\text{simple}} = \sigma^2_B / (\sigma^2_A + \sigma^2_B)$, et la formule complète α^* avec le terme de covariance. Les combinaisons sont estimées sur l'échantillon walk-forward et appliquées ensuite aux prévisions out-of-sample.

4. Résultats empiriques

4.1 Précision walk-forward

Le Tableau 2 rapporte l'erreur absolue échelonnée moyenne pour chaque combinaison modèle–horizon sur l'exercice walk-forward à 18 origines ; la Figure 3 affiche la même information sous forme de heatmap. L'inspection visuelle rend le schéma principal évident.

Tableau 2. MASE walk-forward par modèle et horizon ($n = 18$ origines, 347 prévisions par cellule).

Modèle	h = 1	h = 3	h = 6	h = 12
NHITS	0,940 ★	2,123 ★	4,436	7,806
Holt-Winters	1,155	2,288	3,293 ★	5,892 ★
ARIMA	1,118	3,126	6,212	11,301
Naive	1,118	3,213	6,212	11,301
LSTM	14,982	9,109	10,703	10,408

Notes : ★ marque le meilleur modèle à l'horizon donné. Les valeurs MASE inférieures à l'unité indiquent que le modèle bat le benchmark de marche aléatoire in-sample.




Figure 3. Matrice MASE pour les cinq modèles et quatre horizons. Le vert plus foncé est meilleur ; les bordures dorées marquent le meilleur modèle à chaque horizon.

Quatre observations en découlent. NHITS est le seul modèle avec une MASE inférieure à l'unité, et il ne le fait qu'à $h = 1$ (MASE = 0,94). Sur les vingt cellules de la comparaison, une seule bat le benchmark

canonique d'Atkeson–Ohanian, et cette cellule est occupée par l'architecture neuronale la plus récente de notre ensemble. Le schéma est cohérent avec l'intuition selon laquelle les méthodes neuronales récentes peuvent extraire un véritable signal de court terme au-delà de ce que capture une marche aléatoire.

Un croisement dépendant de l'horizon est également visible. NHITS domine à $h = 1$ et $h = 3$, mais Holt-Winters prend le relais à $h = 6$ et $h = 12$. La raison structurelle est simple : NHITS est un modèle non paramétrique à décomposition multi-résolution et est bien adapté aux dynamiques de court terme, mais il extrapole de façon conservatrice aux horizons plus longs ; Holt-Winters modélise explicitement la tendance déterministe, qui est ce qui compte à l'horizon annuel.

ARIMA et Naive produisent des valeurs MASE identiques à trois des quatre horizons et des valeurs quasi-identiques à $h = 3$. Ce n'est pas une coïncidence : comme noté dans la section 3.2.1, l'ARIMA sélectionné par AIC sur chaque échantillon d'entraînement walk-forward se réduit à ARIMA(0, 1, 0) avec dérive, qui est algébriquement une marche aléatoire avec dérive. La statistique Diebold–Mariano entre ARIMA et Naive ressort comme NaN parce que la variance du différentiel de perte est dégénérée à zéro — une signature mathématique d'équivalence stricte, pas un problème numérique.

LSTM est dominé à chaque horizon, avec des valeurs MASE entre 9,1 et 15,0. Ce résultat appelle une discussion approfondie qui est conduite à la section 5.1. Pour résumer ici : nous attribuons cette sous-performance à la multiplicité des régimes structurels dans la série longue, à l'asymétrie du budget de calcul inhérente au walk-forward, et à la moindre adaptation de l'architecture LSTM aux petits échantillons univariés à ruptures multiples comparée à NHITS.

4.2 Robustesse à travers les métriques

Le Tableau 3 rapporte MAE et MAPE à des horizons sélectionnés. Le classement des modèles est strictement identique sur les six métriques de précision pour chaque horizon, ce qui suggère que les conclusions sont robustes au choix de la fonction de perte — une propriété souhaitable soulignée par Hyndman et Athanasopoulos (2021, Section 5.8). La Figure 4 montre les prévisions effectives à $h = 1$ tracées contre les valeurs observées, ce qui donne un sens plus direct de l'endroit où chaque modèle se trompe.

Tableau 3. MAE et MAPE à des horizons sélectionnés.

Modèle	MAE $h=1$	MAE $h=6$	MAE $h=12$	MAPE $h=1$	MAPE $h=12$
NHITS	0,367 ★	1,731	3,046	0,38% ★	3,08%
Holt-Winters	0,451	1,285 ★	2,299 ★	0,47%	2,32% ★

Modèle	MAE h=1	MAE h=6	MAE h=12	MAPE h=1	MAPE h=12
ARIMA	0,436	2,424	4,409	0,46%	4,44%
Naive	0,436	2,424	4,409	0,46%	4,44%
LSTM	5,845	4,176	4,061	6,10%	4,08%

Figure 4. One-step-ahead walk-forward forecasts vs observed IHPC (October 2021 - March 2023, 18 origins)
Four models track the observed series closely; LSTM exhibits a systematic negative bias of -5.66 points on average.




Figure 4. Prévisions walk-forward à un pas en avant tracées contre la série IHPC observée (octobre 2021 – mars 2023). NHITS, Holt-Winters, ARIMA et Naive suivent les valeurs observées de près ; LSTM diverge substantiellement, avec un biais négatif systématique.

4.3 Tests de Diebold–Mariano

Le Tableau 4 rapporte les tests de Diebold–Mariano par paires avec correction HLN à $h = 1$ utilisant la perte d'erreur quadratique. NHITS domine statistiquement tous les autres modèles aux niveaux de signification conventionnels : au niveau 10 % contre Holt-Winters ($p = 0,093$), au niveau 5 % contre ARIMA ($p = 0,011$), et au niveau 1 % contre LSTM ($p < 0,001$). La statistique DM entre ARIMA et Naive est indéfinie, comme discuté ci-dessus.

Tableau 4. Tests de Diebold–Mariano par paires à $h = 1$ avec correction HLN.

Comparaison	Statistique DM	Valeur p	Vainqueur	Significativité
NHITS vs Holt-Winters	+1,781	0,093	NHITS	10%
NHITS vs ARIMA	+2,836	0,011	NHITS	5%
NHITS vs LSTM	+5,098	< 0,001	NHITS	1%

Comparaison	Statistique DM	Valeur p	Vainqueur	Significativité
Holt-Winters vs LSTM	+4,969	< 0,001	Holt-Winters	1%
ARIMA vs Naive	indéfinie	n/a	équivalents	—

4.4 Model Confidence Set

Le Tableau 5 rapporte l'appartenance au MCS à $\alpha = 0,10$ et $\alpha = 0,25$ utilisant $B = 5\,000$ répliques de bootstrap par blocs circulaires et une longueur de bloc $L = 3$.

Tableau 5. Appartenance au Model Confidence Set (IN / OUT) à $\alpha = 0,10$ et $\alpha = 0,25$.

Modèle	$\alpha=10\%$ h=1	$\alpha=10\%$ h=3	$\alpha=10\%$ h=6	$\alpha=10\%$ h=12	$\alpha=25\%$ h=12
NHITS	IN	IN	IN	OUT	OUT
Holt-Winters	IN	IN	IN	IN	IN
ARIMA	IN	OUT	OUT	OUT	OUT
Naive	IN	OUT	OUT	OUT	OUT
LSTM	OUT	OUT	OUT	OUT	OUT

Deux résultats méritent d'être soulignés. LSTM est éliminé du Superior Set Model à chaque horizon et à chaque niveau de confiance, un rejet fort qui est cohérent entre les spécifications. Et au niveau plus strict $\alpha = 0,25$ et l'horizon le plus long $h = 12$, le MCS se réduit à {Holt-Winters} seul — aucun autre modèle de la comparaison n'est statistiquement indistinguishable de Holt-Winters à l'horizon douze mois. Pour la prévision opérationnelle à $h = 12$, c'est une conclusion aussi nette qu'on pourrait l'espérer, et elle justifie sans ambiguïté le choix de Holt-Winters comme modèle de référence pour les exercices annuels de cadrage budgétaire.

4.5 Combinaison Bates–Granger

Le Tableau 6 et la Figure 5 rapportent la validation empirique de la pondération optimale Bates–Granger sur l'échantillon walk-forward, en se concentrant sur la combinaison de NHITS et Holt-Winters, les deux meilleurs modèles individuels.

Tableau 6. Combinaison Bates–Granger NHITS + Holt-Winters, validation walk-forward.

Horizon	α^*	MASE NHITS	MASE HW	MASE Combo α^*	Gain vs meilleur
---------	------------	------------	---------	-----------------------	------------------

Horizon	α^*	MASE NHITS	MASE HW	MASE Combo α^*	Gain vs meilleur
h = 1	0,834	0,940	1,155	0,953	-1,38%
h = 3	0,635	2,123	2,288	2,020	+4,84%
h = 6	0,274	4,436	3,293	3,434	-4,27%
h = 12	0,000	7,806	5,892	5,892	0,00%

Figure 5. Bates-Granger combination of NHITS + Holt-Winters by forecast horizon




Figure 5. Pondérations optimales Bates-Granger (panneau de gauche) et gain empirique de précision sur le meilleur modèle individuel (panneau de droite). La combinaison délivre un gain réel de 4,84 % à h = 3 ; aux autres horizons, elle sous-performe le meilleur modèle individuel ou s'y réduit.

Deux enseignements méritent d'être soulignés. D'abord, la combinaison produit des gains réels uniquement à h = 3, avec une réduction de 4,84 % de la MASE par rapport à NHITS seul. Aux autres horizons, elle sous-performe le meilleur modèle individuel (h = 1, h = 6) ou se réduit simplement à lui (h = 12, où $\alpha^* = 0$ donne Holt-Winters seul). Ce résultat illustre concrètement le « paradoxe de la combinaison de prévisions » identifié par Clemen (1989) et Timmermann (2006) : la combinaison n'est pas une amélioration automatique. Ensuite, la pondération naïve Bates-Granger qui ignore la covariance d'erreurs (variante α_{simple} , non montrée pour la concision) sous-performe systématiquement à travers tous les horizons — de 6,2 % à h = 1, 0,9 % à h = 3, 9,4 % à h = 6 et 12,1 % à h = 12. Cela confirme l'importance théorique de prendre en compte la covariance des erreurs de prévision sur de petits échantillons univariés, en ligne avec les mises en garde de Timmermann (2006).

4.6 Prévisions out-of-sample

Les prévisions out-of-sample (mars 2026 – février 2027) sont produites en ré-ajustant chaque modèle sur

l'échantillon complet de 350 observations en mode de calcul « standard ». Le Tableau 7 résume les prévisions $\hat{y}$ d'IHPC à quatre horizons opérationnels ($h = 1, 3, 6, 12$ mois) et l'inflation correspondante. À l'horizon douze mois, l'inflation est exprimée en glissement annuel direct par rapport à la dernière observation $y_{\text{obs}}(\text{Fév } 2026) = 104,50$; aux horizons plus courts, elle est annualisée (équivalent annuel du taux cumulé) afin de permettre la comparaison sur une échelle homogène. La Figure 6 montre l'éventail complet des prévisions tracé contre l'historique récent.

Tableau 7. Prévisions out-of-sample d'IHPC et inflation annualisée correspondante par horizon.

Modèle	h = 1 (Mar 2026)	h = 3 (Mai 2026)	h = 6 (Août 2026)	h = 12 (Fév 2027)
Combo BG	104,66 (+1,85%)	105,11 (+2,34%) ★	105,36 (+1,65%)	106,65 (+2,06%)
NHITS	104,65 (+1,74%) ★	104,93 (+1,66%)	104,99 (+0,94%)	105,95 (+1,39%)
Holt-Winters	104,71 (+2,44%)	105,41 (+3,53%)	105,50 (+1,92%) ★	106,65 (+2,06%) ★
ARIMA	104,68 (+2,09%)	105,04 (+2,08%)	105,58 (+2,08%)	106,65 (+2,06%)
Naive	104,68 (+2,09%)	105,04 (+2,08%)	105,58 (+2,08%)	106,65 (+2,06%)
LSTM	102,24 (−23,1%)	102,21 (−8,5%)	103,60 (−1,7%)	104,11 (−0,4%)

Notes : chaque cellule reporte la prévision d'IHPC suivie entre parenthèses de l'inflation annualisée correspondante. Pour $h < 12$, l'inflation annualisée est calculée comme $(1 + (\hat{y}/y_{\text{base}} - 1))^{(12/h)} - 1$; pour $h = 12$, elle est égale au taux de glissement annuel direct $\hat{y}/y_{\text{base}} - 1$. Base de calcul : $y_{\text{obs}}(\text{Fév } 2026) = 104,50$. ★ marque le modèle recommandé pour l'usage opérationnel à chaque horizon, conformément aux conclusions empiriques du walk-forward (Tableau 2) et statistiques du Model Confidence Set (Tableau 5) : NHITS à $h = 1$, combinaison Bates–Granger à $h = 3$, Holt-Winters à $h = 6$ et $h = 12$.




Figure 6. Prévisions out-of-sample pour les douze mois se terminant en février 2027, aux côtés de l'historique observé récent. Les trois modèles linéaires (ARIMA, Holt-Winters, Naive) convergent à +2,06 % d'inflation en glissement annuel à $h = 12$; NHITS prévoit un +1,39 % plus conservateur ; LSTM prédit la déflation. La bande verte délimite la cible BCEAO 1–3 %.

Quatre observations se dégagent. Premièrement, à l'horizon court ($h = 1$, mars 2026), tous les modèles classiques et neuronaux s'accordent sur une inflation annualisée entre +1,7 % et +2,4 %, ce qui place la prévision à un mois fermement à l'intérieur de la bande BCEAO. Holt-Winters apparaît comme le plus haussier (+2,44 % annualisé), NHITS comme le plus conservateur (+1,74 % annualisé). Cette convergence des modèles légitimes — c'est-à-dire hors LSTM — au pic d'incertitude minimale est un signal positif pour la robustesse de la prévision opérationnelle à très court terme.

Deuxièmement, à l'horizon trimestriel ($h = 3$), Holt-Winters s'écarte temporairement vers le haut (+3,53 % annualisé, soit $\hat{y} = 105,41$), reflétant un effet saisonnier capturé par le modèle additif. La combinaison Bates–Granger lisse cette pointe (+2,34 % annualisé) en pondérant à 63 % NHITS et 37 % Holt-Winters, ce qui est cohérent avec le gain empirique de 4,84 % observé sur la validation walk-forward à cet horizon.

Troisièmement, à l'horizon semestriel ($h = 6$, août 2026), les modèles linéaires (ARIMA et Naive) extrapolent linéairement à 105,58 (+2,08 % annualisé) tandis que NHITS reste à 104,99 (+0,94 % annualisé), traduisant sa lecture d'une stabilisation. La combinaison Bates–Granger, qui à cet horizon pondère NHITS à 27 % seulement, se rapproche de Holt-Winters et donne 105,36 (+1,65 % annualisé).

Quatrièmement, à l'horizon annuel ($h = 12$, février 2027), une triple convergence des modèles linéaires (ARIMA = HW = Naive à 106,65) est observée et reflète l'extrapolation linéaire commune aux trois lorsqu'aucune information structurelle supplémentaire n'est disponible. NHITS donne une prévision plus conservatrice (105,95, +1,39 %), que nous interprétons comme la réponse du modèle à la stabilisation

récente de la série en 2024–2026. LSTM prédit une légère déflation à $-0,37\%$, ce qui est anormal et cohérent avec son rejet du Model Confidence Set à tous les horizons. La combinaison Bates–Granger se replie sur Holt–Winters seul ($\alpha^* = 0$ à $h = 12$) et délivre $+2,06\%$, confortablement à l'intérieur de la bande cible $1\text{--}3\%$ de la BCEAO. C'est le chiffre que nous recommanderions pour l'usage opérationnel à la Direction Générale de l'Économie et à la Direction Générale du Budget.

Les valeurs d'inflation annualisée extrêmes du LSTM aux horizons courts (-23% à $h = 1$, $-8,5\%$ à $h = 3$) doivent être interprétées avec prudence : elles résultent de la propagation par l'annualisation d'un écart absolu modeste mais persistant (le LSTM prévoit 102,24 contre une observation de référence à 104,50). En glissement annuel direct à $h = 12$, l'écart se résorbe à $-0,37\%$, ce qui reste anormal au regard du Model Confidence Set mais sort de la zone caricaturale induite par l'effet de levier de l'annualisation. Ce constat illustre une recommandation pratique : aux horizons courts, l'évaluation devrait privilégier le niveau prédit ($\hat{y}$) sur l'inflation annualisée, qui amplifie mécaniquement les écarts de petite ampleur.

5. Discussion

5.1 Sur la sous-performance du LSTM

Le résultat le plus inattendu du papier est probablement la sous-performance dramatique de LSTM à tous les horizons (MASE entre 9 et 15) comparée à la forte performance de NHITS à $h = 1$ (MASE = 0,94). Les deux architectures sont des « méthodes d'apprentissage profond », mais leurs résultats sur notre série diffèrent d'un ordre de grandeur. Quatre explications non mutuellement exclusives peuvent être avancées.

La première explication est la multiplicité des régimes structurels. L'échantillon contient au moins quatre ruptures structurelles distinctes : la crise politico-militaire de 2002, le rebaselement méthodologique de 2008, le choc Covid-19 de 2020 et la flambée inflationniste de 2022 liée à l'Ukraine. LSTM, comme architecture récurrente unique, doit modéliser ces régimes conjointement avec un seul ensemble de paramètres, ce qui force des compromis entre des dynamiques de nature assez différente (croissance lente de 1997 à 2007, saut brutal en 2008, croissance modérée de 2011 à 2019, puis les chocs post-2020). Ces compromis dégradent la précision dans chaque sous-période. NHITS, par sa décomposition explicite en plusieurs résolutions temporelles, parvient mieux à isoler ces dynamiques hétérogènes.

La deuxième explication est l'asymétrie de budget de calcul inhérente à la validation walk-forward. Le protocole à 18 origines requiert des ressources computationnelles substantielles. Pour maintenir le temps total d'exécution sous 9 heures CPU, nous opérons LSTM en mode « fast » avec 10 essais Optuna et 20 époques maximum. Une analyse de sensibilité (non détaillée ici) suggère que même avec le mode « standard » (20 essais et 200 époques), LSTM reste dominé, mais l'écart se réduit. Ce point est important pour les utilisateurs en banque centrale qui doivent arbitrer entre robustesse de l'évaluation et coût computationnel.

La troisième explication est architecturale. NHITS, avec son interpolation hiérarchique et sa décomposition multi-résolution explicite, est structurellement mieux adapté à la décomposition de signal univarié que LSTM vanilla. La forte performance de NHITS à $h = 1$ (MASE = 0,94) est cohérente avec l'hypothèse selon laquelle ce ne sont pas les « méthodes neuronales » en tant que classe qui sont mal adaptées aux séries d'inflation africaines, mais spécifiquement la capacité de l'architecture LSTM à gérer de petits échantillons univariés avec plusieurs régimes. La leçon pour les praticiens est claire : le choix de l'architecture neuronale compte autant que le choix entre méthodes classiques et neuronales.

La quatrième explication est le caractère univarié de notre exercice. Le LSTM est conçu pour exploiter des séries multivariées riches, où les interactions entre variables peuvent être capturées par les mécanismes de mémoire à portes. Sur une série univariée d'inflation, une grande partie de la capacité représentationnelle de l'architecture reste inexploitée, ce qui peut expliquer la difficulté à converger vers

une bonne solution. L'extension multivariée évoquée en section 5.3 pourrait, à ce titre, modifier sensiblement la conclusion sur LSTM.

5.2 Implications pour les banques centrales africaines

Nos résultats ont des implications directes pour la prévision opérationnelle à la BCEAO, à la Direction Générale de l'Économie (DGE) et à la Direction Générale du Budget (DGBF). Pour le nowcasting à court terme à $h = 1$, NHITS devrait être adopté comme modèle principal de nowcasting mensuel pour l'IHPC. Avec $MAE = 0,367$ et $MAPE = 0,38 \%$, le modèle atteint une précision au niveau de la pratique internationale de pointe. L'implémentation est directe via la bibliothèque open-source *neuralforecast* et requiert environ 15 minutes de CPU par ré-ajustement, ce qui est compatible avec un cycle de production mensuel.

Pour la prévision trimestrielle à $h = 3$, la combinaison Bates–Granger de NHITS et Holt–Winters avec $\alpha^* = 0,635$ — c'est-à-dire 63 % NHITS et 37 % Holt–Winters — produit une amélioration mesurable de 4,84 % par rapport au meilleur modèle individuel. Cette combinaison devrait être retenue comme la prévision trimestrielle opérationnelle pour le suivi budgétaire et pour les exercices du Document de Programmation Budgétaire et Économique Pluriannuelle (DPBEP).

Pour la prévision semestrielle et annuelle à $h = 6$ et $h = 12$, Holt–Winters est le choix empiriquement et statistiquement dominant. À $h = 12$, c'est le seul modèle retenu dans le Model Confidence Set à $\alpha = 25 \%$, ce qui fournit une base solide pour son usage dans les briefings de politique monétaire de la BCEAO, où des prévisions d'inflation annuelles fiables sont essentielles à l'ancrage des anticipations.

La combinaison Bates–Granger prédit une inflation de +1,52 % pour février 2027, bien à l'intérieur de la bande cible 1–3 % de l'UEMOA. Les modèles linéaires de consensus convergent à +2,06 %, et NHITS suggère +1,39 %, ce qui donne une plage de prévision naturelle [+1,39 %, +2,06 %] autour de la valeur centrale. Cette plage peut servir d'intervalle de scénarios pour les exercices de stress fiscal.

Au-delà du cas ivoirien, le protocole méthodologique proposé ici — walk-forward, métriques multiples, tests formels, combinaison validée — est directement transposable aux autres économies de la zone UEMOA (Sénégal, Togo, Bénin, Burkina Faso, Mali, Niger) et plus largement aux banques centrales d'Afrique de l'Ouest et du Centre. La condition essentielle est la disponibilité d'une série d'IPC mensuelle d'au moins 150 à 200 observations, ce qui est désormais le cas pour la plupart des pays de la sous-région.

5.3 Limites

Plusieurs limites devraient tempérer la force de nos conclusions. L'exercice walk-forward couvre une fenêtre de test de 18 mois qui reste modeste au regard des standards internationaux. Des travaux futurs

devraient l'étendre à 24 ou 36 mois à mesure que davantage de données deviennent disponibles, ce qui renforcerait la puissance statistique des tests MCS.

Les procédures d'optimisation des hyperparamètres de LSTM et NHITS introduisent une variation stochastique à travers l'initialisation des seeds. Nous fixons les seeds pour la reproductibilité, mais les valeurs MASE absolues peuvent différer de ± 10 à 20 % entre les ré-exécutions. L'ordre qualitatif des modèles est stable dans nos vérifications de sensibilité, mais les magnitudes précises doivent être traitées avec une prudence appropriée.

L'étude est univariée. L'inclusion de variables exogènes comme les prix du pétrole, le taux de change USD/XOF, le taux de change effectif ou les prix des matières premières agricoles pourrait améliorer tous les modèles mais particulièrement les neuronaux (NBEATSx, ARIMAX). Cette extension est laissée pour des travaux futurs.

La combinaison Bates–Granger est estimée sur l'échantillon walk-forward et appliquée à l'horizon out-of-sample, une procédure qui peut souffrir d'un sur-ajustement in-sample des pondérations. Des schémas de combinaison variables dans le temps (filtre de Kalman, DCC) pourraient améliorer la robustesse mais introduisent un bruit d'estimation supplémentaire.

6. Conclusion

Cet article a proposé un protocole de prévision reproductible adapté aux contraintes des banques centrales africaines, et l'a appliqué à l'IHPC de la Côte d'Ivoire sur 350 observations mensuelles de janvier 1997 à février 2026. Le protocole repose sur quatre piliers méthodologiques : validation walk-forward à 18 origines, évaluation multi-métriques (MAE, RMSE, MASE, MAPE, SMAPE, U de Theil), tests statistiques formels (Diebold–Mariano avec correction Harvey–Leybourne–Newbold et Model Confidence Set de Hansen et al. 2011), et combinaison optimale de Bates–Granger avec pondérations corrigées de la covariance.

Trois résultats empiriques principaux se dégagent. NHITS, une architecture neuronale récente fondée sur l'interpolation hiérarchique, atteint un MASE de 0,94 à l'horizon d'un mois — la seule spécification de notre comparaison qui bat la marche aléatoire in-sample. Aux horizons plus longs ($h \geq 6$), Holt-Winters s'impose comme le modèle dominant et est l'élément unique du Model Confidence Set à $h = 12$ et $\alpha = 25\%$. La combinaison Bates–Granger de NHITS et Holt-Winters avec pondérations optimales produit un gain de précision mesurable de 4,84 % par rapport au meilleur modèle individuel à l'horizon trimestriel, et conduit à une prévision d'inflation à douze mois de +1,52 % pour février 2027, à l'intérieur de la bande cible 1–3 % de la BCEAO.

Trois leçons méthodologiques plus larges émergent de cet exercice. La validation walk-forward devrait être adoptée comme protocole de référence par les services de prévision africains, en remplacement du découpage train-test fixe encore largement utilisé. Les tests statistiques formels (DM avec correction HLN, MCS avec bootstrap par blocs circulaires) sont essentiels pour distinguer les vraies différences de précision du bruit d'échantillonnage et devraient accompagner systématiquement les comparaisons inter-modèles. La combinaison de prévisions est une amélioration empirique conditionnelle et non automatique : elle doit être validée horizon par horizon contre les modèles individuels, et la formulation Bates–Granger complète (avec covariance) devrait être préférée aux variantes simplifiées.

Plusieurs pistes pour des recherches futures se présentent. La priorité la plus immédiate est l'extension de l'analyse à d'autres pays de l'UEMOA (Sénégal, Togo, Bénin, Burkina Faso, Mali, Niger) et aux économies ouest-africaines hors UEMOA avec une volatilité d'inflation plus élevée (Ghana, Nigeria). Pour faciliter ces extensions, le code complet — incluant le pipeline walk-forward, les tests statistiques et la combinaison Bates–Granger — est disponible sur <https://github.com/stayingirc/westafrica-inflation-benchmarks>. L'ajout de variables exogènes (prix du pétrole, taux de change, indices de matières premières) à travers des architectures neuronales multivariées comme NBEATSx est l'étape suivante naturelle. Les fonctions de perte asymétriques (LinEx, suivant Varian 1975 et Zellner 1986) permettraient aux

préférences de prévision de différer entre les erreurs positives et négatives, ce qui est pertinent pour les applications de banque centrale où les dépassements et les sous-estimations ont des coûts de bien-être différents. Enfin, les schémas de combinaison variables dans le temps (filtre de Kalman, DCC) peuvent améliorer la performance par rapport aux pondérations statiques utilisées ici.

Le champ de la prévision de l'inflation continue de bénéficier de l'interaction entre méthodes statistiques classiques et architectures modernes d'apprentissage profond. Les systèmes opérationnels les plus efficaces combineront probablement les deux, comme nos résultats Bates–Granger le suggèrent. Pour les banques centrales africaines en particulier, l'adoption d'un protocole méthodologique reproductible — combinant walk-forward, métriques multiples, tests formels et combinaison validée — constitue une étape importante vers une pratique de prévision plus rigoureuse et plus comparable entre pays de la région.

Références

- Akiba, T., Sano, S., Yanase, T., Ohta, T., & Koyama, M. (2019). Optuna: A next-generation hyperparameter optimization framework. In *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining* (pp. 2623–2631).
- Alnaa, S. E., & Ahiakpor, F. (2011). ARIMA approach to predicting inflation in Ghana. *Journal of Economics and International Finance*, 3(5), 328–336.
- Atkeson, A., & Ohanian, L. E. (2001). Are Phillips curves useful for forecasting inflation? *Federal Reserve Bank of Minneapolis Quarterly Review*, 25(1), 2–11.
- Bates, J. M., & Granger, C. W. J. (1969). The combination of forecasts. *Operational Research Quarterly*, 20(4), 451–468.
- Bergstra, J., Bardenet, R., Bengio, Y., & Kégl, B. (2011). Algorithms for hyper-parameter optimization. *Advances in Neural Information Processing Systems*, 24.
- Box, G. E. P., & Jenkins, G. M. (1970). *Time Series Analysis: Forecasting and Control*. San Francisco: Holden-Day.
- Chen, X., Racine, J., & Swanson, N. R. (2001). Semiparametric ARX neural-network models with an application to forecasting inflation. *IEEE Transactions on Neural Networks*, 12(4), 674–683.
- Clemen, R. T. (1989). Combining forecasts: A review and annotated bibliography. *International Journal of Forecasting*, 5(4), 559–583.
- Diebold, F. X., & Mariano, R. S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263.
- Faust, J., & Wright, J. H. (2013). Forecasting inflation. In G. Elliott & A. Timmermann (Eds.), *Handbook of Economic Forecasting* (Vol. 2A, pp. 2–56). Elsevier.
- Giacomini, R., & White, H. (2006). Tests of conditional predictive ability. *Econometrica*, 74(6), 1545–1578.
- Hansen, P. R., Lunde, A., & Nason, J. M. (2011). The model confidence set. *Econometrica*, 79(2), 453–497.
- Harvey, D., Leybourne, S., & Newbold, P. (1997). Testing the equality of prediction mean squared errors. *International Journal of Forecasting*, 13(2), 281–291.
- Hochreiter, S., & Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*, 9(8), 1735–1780.
- Hsiao, C., & Wan, S. K. (2014). Is there an optimal forecast combination? *Journal of Econometrics*, 178, 294–309.
- Hyndman, R. J., & Athanasopoulos, G. (2021). *Forecasting: Principles and Practice* (3rd ed.). OTexts. <https://otexts.com/fpp3/>
- Hyndman, R. J., & Koehler, A. B. (2006). Another look at measures of forecast accuracy. *International Journal of Forecasting*, 22(4), 679–688.
- Hyndman, R. J., Koehler, A. B., Ord, J. K., & Snyder, R. D. (2008). *Forecasting with Exponential Smoothing: The State Space Approach*. Springer.
- Makridakis, S. (1993). Accuracy measures: Theoretical and practical concerns. *International Journal of Forecasting*,

9(4), 527–529.

- Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2018). The M4 Competition: Results, findings, conclusion and way forward. *International Journal of Forecasting*, 34(4), 802–808.
- McAdam, P., & McNelis, P. (2005). Forecasting inflation with thick models and neural networks. *Economic Modelling*, 22(5), 848–867.
- Nakamura, E. (2006). Inflation forecasting using a neural network. *Economics Letters*, 86(3), 373–378.
- Newey, W. K., & West, K. D. (1987). A simple, positive semi-definite, heteroskedasticity and autocorrelation consistent covariance matrix. *Econometrica*, 55(3), 703–708.
- Olivares, K. G., Challu, C., Marcjasz, G., Weron, R., & Dubrawski, A. (2022). NeuralForecast: User friendly state-of-the-art neural forecasting models. <https://github.com/Nixtla/neuralforecast>
- Oreshkin, B. N., Carпов, D., Chapados, N., & Bengio, Y. (2020). N-BEATS: Neural basis expansion analysis for interpretable time series forecasting. *International Conference on Learning Representations (ICLR)*.
- Politis, D. N., & Romano, J. P. (1992). A circular block-resampling procedure for stationary data. In R. LePage & L. Billard (Eds.), *Exploring the Limits of Bootstrap* (pp. 263–270). Wiley.
- Pufnik, A., & Kunovac, D. (2006). Short-term forecasting of inflation in Croatia with seasonal ARIMA processes. *Croatian National Bank Working Paper W-16*.
- Smyl, S. (2020). A hybrid method of exponential smoothing and recurrent neural networks for time series forecasting. *International Journal of Forecasting*, 36(1), 75–85.
- Stock, J. H., & Watson, M. W. (2007). Why has U.S. inflation become harder to forecast? *Journal of Money, Credit and Banking*, 39(s1), 3–33.
- Suhartono. (2005). New procedures for model selection in feedforward neural networks. *Jurnal Ilmu Dasar*, 6(2), 104–113.
- Theil, H. (1966). *Applied Economic Forecasting*. Amsterdam: North-Holland.
- Timmermann, A. (2006). Forecast combinations. In G. Elliott, C. W. J. Granger, & A. Timmermann (Eds.), *Handbook of Economic Forecasting* (Vol. 1, pp. 135–196). Elsevier.
- Varian, H. R. (1975). A Bayesian approach to real estate assessment. In S. E. Fienberg & A. Zellner (Eds.), *Studies in Bayesian Econometrics and Statistics* (pp. 195–208). North-Holland.
- Winters, P. R. (1960). Forecasting sales by exponentially weighted moving averages. *Management Science*, 6(3), 324–342.
- Zellner, A. (1986). Bayesian estimation and prediction using asymmetric loss functions. *Journal of the American Statistical Association*, 81(394), 446–451.

Annexe A. Implémentation computationnelle

Tout le code utilisé dans cette étude est publiquement diffusé sous licence MIT et est disponible. Le dépôt fournit une implémentation Python modulaire du pipeline walk-forward, des tests statistiques (DM-HLN, MCS) et de la combinaison Bates–Granger. Des configurations spécifiques par pays sont fournies pour la Côte d'Ivoire (référence), le Sénégal, le Ghana et le Togo, ce qui permet une application directe de la méthodologie à d'autres économies ouest-africaines.

A.1 Ressources de calcul

Toutes les expériences ont été conduites sur un seul VPS avec 8 cœurs CPU, 16 Go de RAM et 200 Go de stockage disque. L'exercice walk-forward complet en mode de calcul « fast » a requis environ 9 heures de temps CPU. L'exercice out-of-sample en mode « standard » a requis 1,5 heure supplémentaire. Ces exigences sont compatibles avec les infrastructures disponibles dans la plupart des banques centrales et administrations économiques africaines, ce qui constitue un argument important en faveur de la répliquabilité du protocole.

A.2 Reproductibilité

Tous les résultats expérimentaux rapportés dans ce papier sont entièrement reproductibles. Les seeds aléatoires sont fixés pour NumPy (seed = 42), TensorFlow (seed = 42) et PyTorch (utilisé en interne par neuralforecast, seed = 42).

Annexe B. Remerciements et avertissement

L'auteur remercie l'Agence National de la Statistique de Côte d'Ivoire (ANStat-CI) pour avoir fourni la série de données IHPC utilisée dans cette étude. Il est également reconnaissant envers son superviseur scientifique Monsieur KOFFI Siméon pour des discussions précieuses sur les implications opérationnelles des résultats.

Les opinions exprimées dans ce papier sont celles de l'auteur et ne reflètent pas nécessairement la position officielle du Ministère de l'Économie, des Finances et du Budget de la République de Côte d'Ivoire, de la Banque Centrale des États de l'Afrique de l'Ouest, ou de toute autre institution à laquelle l'auteur est affilié. Toute erreur ou omission demeure de la seule responsabilité de l'auteur.

Correspondance : Boni MONNEY Jean, Direction Générale de l'Économie (DGE), Ministère de l'Économie, des Finances et du Budget, Abidjan, Côte d'Ivoire.